（十四）基于新闻文本的股价波动预测与因果关系初探

- 关键词：Python，时间序列分析，自然语言处理，情感分析，回归分析，因果推断，机器学习，知识图谱
- 任务难度：☑☑☑☑☐
- 任务描述：在金融市场中，新闻信息被认为是影响资产价格的重要因素之一。本题目旨在探索新闻文本与股票价格波动之间的关系。
  1. 从公开数据源获取某一只股票或指数的历史价格数据（如日频数据）；
  2. 收集对应时间段内的相关新闻数据（可使用公开新闻 API 或爬虫）；
  3. 对新闻文本进行处理（如情感分析、关键词提取或事件分类）；
  4. 构造一个简单指标（例如每日情绪指数或新闻强度）；
  5. 分析该指标与股票收益或波动之间的关系；
  6. 尝试回答：新闻是否对市场具有“预测能力”？
- 鼓励但不强制：
  - 使用统计检验方法（如 Granger 因果检验）
  - 对比不同文本处理方法（词典法 vs. LLM 法）的效果差异；
  - 分析情感信号的衰减效应（如使用指数衰减模型处理非交易日新闻）；
  - 尝试构建简单的“新闻事件-股价反应”知识图谱或关系图；
  - 区分不同来源（官方公告 vs. 媒体报道）、不同类型（公司层面 vs. 行业政策）新闻的影响差异；
  - 讨论“市场有效性”在不同情境下的体现；
  - 识别并分析可能的“伪因果”案例。
- 最终提交内容包括：
  - 方法说明（不超过 4 页）：清晰阐述数据来源、处理流程、分析模型、主要结果及其经济学/金融学解释，重点说明对因果性的思考和讨论。
  - 核心代码和可复现结果：提供完整、注释良好的 Python 代码（Jupyter Notebook 格式为佳），以及关键结果的图表和数据。
  - 上述内容上传至自己账号下的 github 仓库 repo 中，报名回复该仓库 repo 链接即为上传作业成功。

  （本题不要求复杂模型实现，更关注对数据的理解能力、合理建模以及对“相关性与因果性差异”的认识。）
- Hint 1：数据来源
  - 股票：Yahoo Finance、Tushare、Akshare
  - 新闻：NewsAPI、**GDELT**（强烈推荐）、Fred、东方财富、财联社、金十数据等国内新闻
- Hint 2：最简单可行方案（baseline）：用词典法做情绪分析；每天求平均

sentiment；然后做回归: return_t ~ sentiment_{t-1}

- Hint 3：进阶方向：滞后效应（lag 1~5 days）；高频 vs 低频；不同类型新闻（政策 vs 公司）；能识别伪因果；能讨论“信息延迟”“市场有效性”“confounding variables”
- 可参考的资料：
  - 《Advances in Financial Machine Learning》by Marcos López de Prado
  - 《Python for Finance》
  - Tetlock (2007)“Giving Content to Investor Sentiment”(新闻情绪→市场影响的经典工作), https://www.uts.edu.au/globalassets/sites/default/files/adg_cons2015_tetlock-journal-of-finance-2007.pdf
  - statsmodels（因果检验）：https://github.com/statsmodels/statsmodels 豆瓣电影短评情绪分析：https://github.com/iphysresearch/TOP250movie_douban ；https://arxiv.org/abs/2411.13965
  - 《FNSPID: A Comprehensive Financial News Dataset in Time Series (2024)，了解大规模新闻-股价对齐数据集的价值与构建，https://arxiv.org/abs/2402.06698
  - Sentiment trading with large language models (2024)，了解 LLM 在金融情感分析中的前沿应用与卓越表现，https://arxiv.org/abs/2412.19245
  - News-Aware Direct Reinforcement Trading for Financial Markets (2025)，了解如何将新闻情感特征直接整合至机器学习/强化学习模型 https://arxiv.org/abs/2510.19173
  - JP Morgan：融合 NLP 情绪与 LLM 洞察的配对交易策略（2026），了解业界如何系统化运用新闻情绪与 LLM 事件分类于量化策略 https://mp.weixin.qq.com/s/8Q06yZxG1Lgu4JWwsCNk6A
  - HuggingFace（NLP）；
  - statsmodels（因果检验）；
  - 豆瓣电影短评情绪分析：https://github.com/iphysresearch/TOP250movie_douban
  - https://arxiv.org/abs/2411.13965